

**Republic of Yemen**  
**IBB University**  
**Faculty of Science**  
**Department of IT**  
**Data Mining**



**الجمهورية اليمنية**  
**جامعة إب**  
**كلية العلوم التطبيقية**  
**قسم : تقنية معلومات**  
**مقرر : تنقيب البيانات**

الطلاب التالية أسمائهم

- ايمن محمد ناجي قمحان
- ضياء فضل الحضرمي
- حازم هزام العمري

## **DEMAND FORECASTING**

**Mission is to create a 3-month demand forecasting model for the relevant store chain using the following time series and machine learning techniques:**

**Random Noise**

**Lag Shifted Features**

**Rolling Mean Features**

**Exponentially Weighted Mean Features**

**Custom Cost Function**

**Model Validation with LightGBM**

**Solving the problem of multiple unclear products in some markets and some products required by customers are not available. This model predicts the impact of products on purchasing in a shopping period and a decision is made to purchase the most demanded products and reduce the demand for those with scarce demand.**

**Dataset is here: <https://www.kaggle.com/c/demand-forecasting>**

## **Dataset Description**

**The objective of this competition is to predict 3 months of item-level sales data at different store locations.**

## **File descriptions**

**train.csv - Training data**

**test.csv - Test data (Note: the Public/Private split is time based)**

**sample\_submission.csv - a sample submission file in the correct format**

**Data fields**

**date - Date of the sale data. There are no holiday effects or store closures.**

**store - Store ID**

**item - Item ID**

**sales - Number of items sold at a particular store on a particular date**

### **In Arabic language**

الهدف من المشروع كالتالي :

التنبؤ بالطلب للمتاجر

المهمة هي إنشاء نموذج تنبؤ بالطلب لمدة 3 أشهر لسلسلة المتاجر المعنية باستخدام السلاسل الزمنية وتقنيات التعلم الآلي التالية:

الضوضاء العشوائية

خصائص التأخير المُحوّل

خصائص المتوسط المنحدر

خصائص المتوسط المرجح أسياً

دالة التكلفة المُخصصة

التحقق من صحة النموذج باستخدام LightGBM

حل مشكلة وهي تعدد المنتجات غير المرغوبة في بعض المتاجر وبعض المنتجات المطلوبة لدى العملاء لا يتم توفيرها فهذا المودل يتنبئ في المنتجات الأثر شراء في المتجر في مده معينة ومنة يتم اتخاذ قرار لشراء المنتجات الأكثر طلباً وتقليل الطلب للمنتجات التي لديها طلب شحيح

مجموعة البيانات متوفرة هنا: <https://www.kaggle.com/c/demand-forecasting>

وصف مجموعة البيانات

الهدف من هذه المسابقة هو التنبؤ ببيانات مبيعات المنتجات على مدار ثلاثة أشهر في مواقع متاجر مختلفة.

وصف الملفات

train.csv - بيانات التدريب

**test.csv** - بيانات الاختبار (ملاحظة: التقسيم بين عام وخاص يعتمد على الوقت)

**sample\_submission.csv** - نموذج لملف الإرسال بالتنسيق الصحيح

حقول البيانات

**date** - تاريخ بيانات البيع. لا توجد عطلات أو إغلاقات للمتاجر.

**store** - معرف المتجر

**item** - معرف المنتج

**sales** - عدد المنتجات المباعة في متجر معين في تاريخ محدد.

هنا تم جلب البيانات

## Store Item Demand Forecasting Challenge

Predict 3 months of item sales at different stores



```

1 # HELPER FUNCTIONS (UTILS)
2
3 # Check dataframe
4 def check_df(dataframe, head=5, tail=5, quan=False):
5     print("##### Shape #####")
6     print(dataframe.shape)
7     print("##### Types #####")
8     print(dataframe.dtypes)
9     print("##### Head #####")
10    print(dataframe.head(head))
11    print("##### Tail #####")
12    print(dataframe.tail(tail))
13    print("##### NA #####")
14    print(dataframe.isnull().sum())
15
16    if quan:
17        print("##### Quantiles #####")
18        print(dataframe.quantile([0, 0.05, 0.50, 0.95, 0.99, 1]).T)
19
20 # Date Features
21 def create_date_features(df):
22     df['month'] = df.date.dt.month
23     df['day_of_month'] = df.date.dt.day
24     df['day_of_year'] = df.date.dt.dayofyear
25     df['week_of_year'] = df.date.dt.weekofyear
26     df['day_of_week'] = df.date.dt.dayofweek
27     df['year'] = df.date.dt.year
28     df['is_wknd'] = df.date.dt.weekday // 4
29     df['is_month_start'] = df.date.dt.is_month_start.astype(int)
30     df['is_month_end'] = df.date.dt.is_month_end.astype(int)
31     return df
32
33 # Random Noise
34 def random_noise(dataframe):
35     return np.random.normal(scale=1.6, size=(len(dataframe),))
36
37 # Lag/Shifted Features
38 def lag_features(dataframe, lags):
39     for lag in lags:
40         dataframe['sales_lag_' + str(lag)] = dataframe.groupby(["store", "item"])['sales'].transform(
41             lambda x: x.shift(lag)) + random_noise(dataframe)
42     return dataframe
43
44 # Rolling Mean Features
45 def roll_mean_features(dataframe, windows):
46     for window in windows:
47         dataframe['sales_roll_mean_' + str(window)] = dataframe.groupby(["store", "item"])['sales']. \
48             transform(
49                 lambda x: x.shift(1).rolling(window=window, min_periods=10, win_type="triang").mean()) + random_noise(
50                 dataframe)
51     return dataframe
52
53 # Exponentially Weighted Mean Features
54 def ewm_features(dataframe, alphas, lags):
55     for alpha in alphas:
56         for lag in lags:
57             dataframe['sales_ewm_alpha_' + str(alpha).replace(".", "") + "_lag_" + str(lag)] = \
58                 dataframe.groupby(["store", "item"])['sales'].transform(lambda x: x.shift(lag).ewm(alpha=alpha).mean())
59     return dataframe
60
61 # Custom Cost Function
62 def smape(preds, target):
63     n = len(preds)
64     masked_arr = ~((preds == 0) & (target == 0))
65     preds, target = preds[masked_arr], target[masked_arr]
66     num = np.abs(preds - target)
67     denom = np.abs(preds) + np.abs(target)
68     smape_val = (200 * np.sum(num / denom)) / n
69     return smape_val
70
71 def lgbm_smape(preds, train_data):
72     labels = train_data.get_label()
73     smape_val = smape(np.expm1(preds), np.expm1(labels))
74     return 'SMAPE', smape_val, False
75
76 # Feature Importance
77 def plot_lgb_importances(model, plot=False, num=10):
78
79     gain = model.feature_importance('gain')
80     feat_imp = pd.DataFrame({'feature': model.feature_name(),
81                             'split': model.feature_importance('split'),
82                             'gain': 100 * gain / gain.sum()}).sort_values('gain', ascending=False)
83
84     if plot:
85         plt.figure(figsize=(10, 10))
86         sns.set(font_scale=1)
87         sns.barplot(x="gain", y="feature", data=feat_imp[0:25])
88         plt.title('feature')
89         plt.tight_layout()
90         plt.show()
91     else:
92         print(feat_imp.head(num))
93
94 # Kaggle input part
95 import os
96 for dirname, _, filenames in os.walk('/kaggle/input'):
97     for filename in filenames:
98         print(os.path.join(dirname, filename))

```

## ات من منصة Kaggle

يقوم هذا الكود بتهيئة بيئة العمل الخاصة بتحليل البيانات والتعلم الآلي عبر استيراد المكتبات التالية:

- numpy , pandas لتحليل البيانات ومعالجتها.
- matplotlib, seaborn للرسم البياني.
- Lightgbm لبناء نموذج تعلم آلي فعال.
- LabelEncoder لتحويل البيانات الفئوية إلى عددية.
- إعدادات عرض pandas وتحكم في رسائل التحذير لتحسين تجربة المستخدم.

```
1 # Import necessary libraries and make necessary arrangements
2 import time
3 import numpy as np
4 import pandas as pd
5 from matplotlib import pyplot as plt
6 import seaborn as sns
7 import lightgbm as lgb
8 import warnings
9 from sklearn.preprocessing import LabelEncoder
10
11 pd.set_option('display.max_columns', None)
12 pd.set_option('display.width', 500)
13 warnings.filterwarnings('ignore')
```

## \*دالة لفحص وتحليل أولي لبيانات DataFrame

تعرض التالي:

- الشكل العام للبيانات عدد الصفوف، الأعمدة
- أنواع البيانات لكل عمود
- أول وآخر عدد معين من الصفوف (افتراضي 5)
- عدد القيم المفقودة في كل عمود
- إذا تم تفعيل quan=True، تُعرض أيضًا القيم المئوية (Quantiles)

```
1 def check_df(dataframe, head=5, tail=5, quan=False):
2
```

\* تُستخدم لاستخراج ميزات مشتقة من التاريخ من عمود date، مثل:

- الشهر، اليوم من الشهر، اليوم من السنة
  - الأسبوع، اليوم من الأسبوع، السنة
  - هل التاريخ في بداية أو نهاية الشهر؟
  - هل اليوم عطلة (نهاية أسبوع)؟
- هذه الميزات تساعد النماذج على فهم الأنماط الزمنية.

```
1 def check_df(dataframe, head=5, tail=5, quan=False):
2
```



```
1 def random_noise(dataframe):  
2
```

\* تُضيف ضجيج عشوائي (Noise) إلى البيانات، وهو أمر مفيد لمنع النماذج من التعلّم الزائد (Overfitting)



```
1 def lag_features(dataframe, lags):  
2
```

تُنشئ ميزات الإزاحة الزمنية (Lag) للمبيعات السابقة، مثل مبيعات اليوم السابق، أو قبل يومين، إلخ.

- تقوم بذلك لكل مجموعة (store, item)
- تُستخدم هذه الميزات لتعليم النموذج العلاقة بين مبيعات اليوم والأيام السابقة



```
1 def roll_mean_features(dataframe, windows):  
2
```

\* تُنشئ ميزات المتوسط المتحرك (Rolling Mean) باستخدام نافذة window معينة.

- مفيدة لتحليل الاتجاهات على مدى زمني معين.
- تُستخدم دالة rolling() مع نوع نافذة مثل "tiring".



```
1 def ewm_features(dataframe, alphas, lags):  
2
```

\* تُنشئ ميزات المتوسط المرجح أسياً (EWM)، الذي يعطي وزناً أكبر للبيانات الأحدث.

- ❖ alpha يتحكم بمقدار الوزن للبيانات الحديثة.
- ❖ تُطبق لكل مجموعة (store, item) على بيانات المبيعات.



```
1 def smape(preds, target):  
2
```

\* دالة لحساب **SMAPE - Symmetric Mean Absolute Percentage Error**، وهي مقياس دقيق لتقييم النماذج التي تتنبأ بقيم مستمرة، خصوصًا في السلاسل الزمنية.

❖ تعطي نتائج بين 0 و100 كلما اقتربت من 0 كان النموذج أفضل



```
1 def lgbm_smape(preds, train_data):  
2
```

\* تُستخدم لربط SMAPE بنموذج LightGBM كتقييم مخصص (custom metric) أثناء التدريب.

❖ تُحوّل القيم من Log إلى طبيعتها قبل التقييم باستخدام `np.exp(m1)`



```
1 def plot_lgb_importances(model, plot=False, num=10):  
2
```

\* تعرض أو تطبع أهمية الميزات (Feature Importance) في نموذج LightGBM.

❖ تعتمد على طريقتين: عدد الانقسامات (split) أو إجمالي التأثير (gain).

❖ عند تفعيل `plot=True` ترسم رسمًا بيانيًا لأهم 25 ميزة.



```
1 import os  
2 for dirname, _, filenames in os.walk('/kaggle/input'):  
3     for filename in filenames:  
4         print(os.path.join(dirname, filename))  
5
```

جزء قراءة البيانات من كاجل

يُستخدم للحصول على قائمة بكل الملفات الموجودة في مجلد `/kaggle/input`.

❖ مفيد عند استخدام منصة Kaggle للتأكد من الملفات المتاحة للقراءة.



```
1 df = pd.concat([train, test], sort=False)
2
```

- ❖ هذا القسم يقوم بتحميل البيانات وتحضيرها للمعالجة.
- ❖ تم دمج بيانات التدريب والاختبار لتسهيل معالجة موحدة لجميع البيانات.
- ❖ لاحقاً سيتم فصلهم مرة أخرى عند بناء النموذج والتنبؤ.



```
1 df["date"].min(), df["date"].max()
2 train["date"].min(), train["date"].max()
3 test["date"].min(), test["date"].max()
4
```

### التحليل والاستكشاف الأولي

\*نتحقق من نطاق التواريخ في كل من البيانات الكاملة (df) والتدريب (train) والاختبار (test).



```
1 check_df(train)
2 check_df(test)
3 check_df(df)
4
```

- ❖ نستخدم الدالة check\_df التي شرحناها سابقاً لفحص كل مجموعة بيانات: عدد الأعمدة، القيم المفقودة، أنواع البيانات، إلخ.



```
1 df["sales"].describe([0.10, 0.30, 0.50, 0.70, 0.80, 0.90, 0.95, 0.99])
2
```

- ❖ نُحلل توزيع المبيعات باستخدام إحصائيات مئوية لتحديد القيم المتطرفة والوسيط.



## معلومات حول المتاجر والمنتجات

❖ نحصل على:

❖ عدد المتاجر الفريد

❖ عدد العناصر الفريدة

❖ عدد العناصر المتاحة في كل متجر

```
1 df[["store"]].nunique()
2 df[["item"]].nunique()
3 df.groupby(["store"])["item"].nunique()
4
```

❖ تحليل المبيعات حسب كل متجر وعُنصر: مجموع، متوسط، وسيط، وانحراف معياري.

```
1 df.groupby(["store", "item"]).agg({"sales": ["sum", "mean", "median", "std"]})
2
```

## استخراج ميزات تاريخية

❖ نحول العمود date إلى صيغة زمنية، ثم نستخدم دالة create\_date\_features لاستخراج:

❖ الشهر، الأسبوع، السنة، بداية/نهاية الشهر، إلخ.

```
1 df['date'] = pd.to_datetime(df['date'])
2 df = create_date_features(df)
3 check_df(df)
4
```

❖ تحليل شهري للمبيعات حسب المتجر والعنصر.

```
1 df.groupby(["store", "item", "month"]).agg({"sales": ["sum", "mean", "median", "std"]})
2
```

### مميزات الإزاحة الزمنية (Lag Features)

- ❖ بعد فرز البيانات زمنياً، ننشئ مميزات للمبيعات السابقة (Lagged Sales)، وهي مهمة جداً للتنبؤ بناءً على القيم السابقة.

### المتوسطات المتحركة

- ❖ نُضيف مميزات للمتوسطات المتحركة طويلة المدى (سنة، سنة ونصف)، مما يساعد على التقاط الاتجاهات.

### (EWM) المتوسطات الأسية المرجحة

- ❖ نُنشئ مميزات تأخذ في الاعتبار الأوزان الزمنية للأسابيع أو الأشهر الماضية، حيث تُعطى أهمية أكبر للقيم الأحدث.

### كود التحضير للنموذج

- ❖ نحول المتغيرات الفئوية (store, item, ...) إلى تمثيل رقمي باستخدام **One-Hot Encoding**.
- ❖ نحول المبيعات إلى القيمة اللوغاريتمية لتقليل تأثير القيم المتطرفة.

\*- نقسم البيانات زمنياً للتدريب :

- ❖ مجموعة التدريب حتى نهاية 2016
- ❖ مجموعة التحقق هي أول 3 شهور من 2017، لمحاكاة التنبؤ في 2018

```
1 df.sort_values(by=['store', 'item', 'date'], axis=0, inplace=True)
2 df = lag_features(df, [91, 98, 105, 112, 119, 126, 182, 364, 546, 728])
3
```

```
1 df = roll_mean_features(df, [365, 546])
2
```

```
1 alphas = [0.95, 0.9, 0.8, 0.7, 0.5]
2 lags = [91, 98, 105, 112, 180, 270, 365, 546, 728]
3 df = ewm_features(df, alphas, lags)
4
```

```
1 df = pd.get_dummies(df, columns=['store', 'item', 'day_of_week', 'month'])
2 df['sales'] = np.log1p(df["sales"].values)
3
```

```
1 train = df.loc[(df["date"] < "2017-01-01"), :]
2 val = df.loc[(df["date"] >= "2017-01-01") & (df["date"] < "2017-04-01"), :]
3
```

```

1 Y_train = train['sales']
2 X_train = train[cols]
3 Y_val = val['sales']
4 X_val = val[cols]
5

```

+ نحدد المتغير المستهدف (sales) والمتغيرات المدخلة (cols) يجب أن تحتوي على أسماء الأعمدة التي تم استخراجها).

```

1 Y_train.shape, X_train.shape, Y_val.shape, X_val.shape
2

```

\* نتأكد من صحة أبعاد البيانات قبل التدريب.

```

1 lgb_params = {
2     'metric': {'mae'},
3     'num_leaves': 10,
4     'learning_rate': 0.02,
5     'feature_fraction': 0.8,
6     'max_depth': 5,
7     'verbose': 0,
8     'num_boost_round': 1000,
9     'early_stopping_rounds': 200,
10    'nthread': -1
11 }
12

```

- إعدادات نموذج LightGBM:

- ❖ mae مقياس الخطأ
- ❖ num\_leaves, max\_depth تتحكم بتعقيد النموذج
- ❖ early\_stopping\_rounds توقف التدريب عند عدم التحسن
- ❖ learning\_rate معدل التعلم الصغير لتجنب التذبذب

```

1 lgbtrain = lgb.Dataset(data=X_train, label=Y_train, feature_name=cols)
2 lgbval = lgb.Dataset(data=X_val, label=Y_val, reference=lgbtrain, feature_name=cols)
3

```

❖ إعداد بيانات التدريب والتحقق لاستخدامها في نموذج LightGBM.

```

1 model = lgb.train(
2     lgb_params,
3     lgbtrain,
4     valid_sets=[lgbtrain, lgbval],
5     num_boost_round=lgb_params['num_boost_round'],
6     callbacks=[lgb.early_stopping(lgb_params['early_stopping_rounds']), lgb.log_evaluation(100)],
7     feval=lgbm_smape
8 )
9

```

❖ تدريب النموذج باستخدام:

❖ التحقق المبكر (Early stopping)

❖ تقييم مخصص عبر SMAPE

❖ طباعة النتائج كل 100 جولة

تقييم النموذج على مجموعة التحقق

```

1 y_pred_val = model.predict(X_val, num_iteration=model.best_iteration)
2 smape(np.expm1(y_pred_val), np.expm1(Y_val))
3

```

❖ نقوم بالتنبؤ على مجموعة التحقق (X\_val) باستخدام

أفضل تكرار من التدريب (best\_iteration)

\* ثم نحسب SMAPE على القيم الأصلية (بعد عكس log1p باستخدام np.expm1 لتقييم دقة النموذج).

عرض اهم الميزات

```

1 plot_lgb_importances(model, num=30, plot=True)
2

```

❖ نستخدم دالة plot\_lgb\_importances لرسم أهمية الميزات في النموذج النهائي، مما يساعدنا على فهم ما يؤثر أكثر على التنبؤ.

```

1 train = df.loc[~df.sales.isna()]
2 test = df.loc[df.sales.isna()]
3

```

### تدريب النموذج النهائي

❖ يتم استخدام كامل بيانات التدريب لتدريب النموذج النهائي، واستبعاد الصفوف التي لا تحتوي على sales (وهي مجموعة الاختبار).

```

1 lgb_params = {..., "num_boost_round": model.best_iteration}
2 model = lgb.train(lgb_params, lgbtrain_all, num_boost_round=model.best_iteration)
3

```

❖ نستخدم أفضل عدد تكرارات تم الحصول عليه سابقًا لتدريب نموذج قوي على كامل البيانات.

```

1 submission_df = test.loc[:, ['id', 'sales']]
2 submission_df['sales'] = np.expml(test_preds)
3 submission_df['id'] = submission_df.id.astype(int)
4 submission_df.to_csv('submission_demand.csv', index=False)
5

```

### إنشاء ملف التقديم Submission

❖ نحضر الملف حسب تنسيق مسابقة كاجل:

- نستخدم gid sales
- نحول القيم من log إلى القيم الأصلية

### حفظ النموذج وملف التقييم

نحفظ :

```
1 with open('/content/drive/My Drive/lgbm_model.pkl', 'wb') as model_file:
2     pickle.dump(model, model_file)
3 submission_df.to_csv('/content/drive/My Drive/submission_demand.csv', index=False)
4
```

❖ النموذج المدرب بصيغة .pkl.

❖ ملف النتائج بصيغة .csv.

\* يتم حفظ كل ذلك في **Google Drive** لاستخدامه لاحقاً أو تحميله.

### تحميل النموذج نخليه لاحقاً

❖ نستخدم مكتبة pickle لإعادة تحميل النموذج عند الحاجة دون إعادة تدريبه.

```
1 with open('/content/drive/MyDrive/lgbm_model.pkl', 'rb') as f:
2     model = pickle.load(f)
3
```

### التنبؤ اليدوي لمتجر معين

❖ نُجهز هذه الدالة إدخال يدوي لتنبؤ مبيعات منتج معين في متجر معين في تاريخ معين:

```
1 def prepare_input(store, item, date_str, feature_columns): ...
2
```

❖ يتم استخراج خصائص التاريخ

❖ يتم تنفيذ One-Hot Encoding

❖ ملء الأعمدة الناقصة بـ 0

❖ ترتيب الأعمدة تماماً كما في التدريب

```
1 input_df = prepare_input(store=3, item=25, date_str='2018-01-01', feature_columns=cols)
2 prediction = model.predict(input_df)[0]
3
```

❖ يتم تمرير البيانات إلى النموذج للحصول على توقع المبيعات لليوم المحدد.

❖ يتم رسم الرسم البياني الذي يُظهر قيمة المبيعات المتوقعة بشكل مرئي أنيق.

```
1 plt.bar(['Predicted Sales'], [prediction], color='green')
2
```

## خلاصة المشروع: توقع الطلب باستخدام LightGBM

- قمنا ببناء نموذج دقيق لتوقع المبيعات اليومية لكل منتج في كل متجر باستخدام تقنيات تعلم الآلة.
- اعتمدنا على تحويل البيانات الزمنية إلى ميزات ذكية مثل:
  - الإزاحات الزمنية (Lag Features)
  - المتوسطات المتحركة (Rolling Mean)
  - المتوسطات الأسية المرجحة (EWM)
  - مؤشرات التاريخ (الشهر، اليوم، بداية/نهاية الشهر... إلخ)
- استخدمنا نموذج **LightGBM** نظراً لسرعته ودقته مع البيانات الكبيرة.
- تم تقييم النموذج باستخدام مقياس **SMAPE** لضمان جودة التنبؤ.
- بعد التحقق درّبنا نموذجاً نهائياً على كامل البيانات وولّدنا ملف التقديم النهائي.
- أنشأنا دالة للتنبؤ اليدوي بأي تاريخ/منتج/متجر، مع عرض النتائج بطريقة رسومية بسيطة.

## النتيجة ...

نموذج فعال قادر على دعم اتخاذ القرار في التخطيط للمخزون، التسعير، وإدارة الطلبات بكفاءة عالية.

إشراف المهندس / فؤاد الدغار